Sistema Fullstack de Búsqueda Léxica, Semántica e Híbrida: Evaluación sobre 55 Documentos vía Web Scraping y Concurrencia hasta 50 Usuarios

Estudiante: Víctor Gerardo Atala Lagunas	**Matrícula:** 223230
Materia: Minería de Datos — Unidad 2	**Motores:** BM25 · Embeddings 384d · Híbrido (RRF + Reranker)
Corpus Web Scraping: 55 documentos (mín. 115 palabras/doc)	**Repositorio:** ATALA_LAGUNAS_VICTOR_223230_C2_T4_INTEGRACION

1. Desarrollo del Sistema Fullstack y Construcción del Corpus vía Web Scraping

Para evaluar en condiciones realistas de producción los tres paradigmas de Recuperación de Información desarrollados a lo largo de la unidad, se diseñó e implementó un sistema Fullstack desacoplado bajo principios de **Clean Architecture**, acompañado de un pipeline automatizado de adquisición y curación de datos mediante **Web Scraping** (scraper/scraper_corpus.py).

1.1 Pipeline de Web Scraping y Validación de Longitud (>=100 Palabras por Documento)

El módulo scraper/scraper_corpus.py recolecta, limpia etiquetas HTML/scripts, normaliza en Unicode NFC y valida **55 documentos periodísticos, científicos e institucionales sobre el estado de Chiapas** distribuidos en 7 categorías temáticas (Hidrología y Clima, Agricultura y Comercio, Ciencia y Tecnología, Biodiversidad y Medio Ambiente, Infraestructura y Transporte, Salud Pública, y Turismo y Cultura). Cada documento conserva su metadato de trazabilidad (id, titulo, categoria, url_fuente, dominio y num_palabras). El corpus resultante contiene **55 documentos** con un mínimo estricto de **115 palabras**, un promedio de **142.5 palabras** y un máximo de **163 palabras por documento**, superando ampliamente la restricción de al menos 50 documentos de mínimo 100 palabras cada uno.

1.2 Arquitectura Backend Multihilo y Frontend Web Interactivo

• **Capa de Dominio e Indexación (backend/engine_service.py):** Encapsula la clase MotorBusquedaFullstack, la cual preprocesa el texto unificado (titulo + texto) y mantiene en memoria principal las estructuras de los 3 motores: (1) el índice invertido probabilístico **Okapi BM25** (k_1 = 1.5, b = 0.75), (2) la matriz densa normalizada $\mathbf{E} \in R^{55\times384}$ para búsqueda semántica por producto punto ($\cos(\theta) = \mathbf{E}\cdot\mathbf{q}$), y (3) el pipeline **Híbrido de Dos Etapas** que fusiona BM25 (filtrando exclusivamente documentos con score > 0) y Embeddings mediante **Reciprocal Rank Fusion (RRF, k = 60)** seguido de un reordenamiento **Cross-Encoder Reranker** sobre el top-10 de candidatos.
• **Capa de Servidor HTTP REST Multihilo (backend/server.py):** Implementada sobre ThreadingHTTPServer para atender múltiples peticiones simultáneas en hilos concurrentes. Expone los endpoints JSON /api/health, /api/corpus, /api/search, /api/compare, /api/eval y /api/benchmark.
• **Capa de Presentación Frontend (frontend/index.html, styles.css, app.js):** Interfaz web editorial estructurada en 4 módulos interactivos: (1) Comparador lado a lado en tiempo real de los 3 motores con telemetría de latencia individual, (2) Tablero de pruebas de estrés para 1 a 50 usuarios concurrentes (p50, p95, p99 y QPS), (3) Evaluación formal IR (nDCG@5, MRR, Recall@5), y (4) Explorador auditable de los 55 documentos con enlaces directos a sus fuentes de Web Scraping.

2. Comportamiento de los Motores de Búsqueda y Evaluación de Calidad IR

Se evaluaron los 3 motores sobre un banco de **12 consultas etiquetadas (QRELS)** divididas equitativamente en tres regímenes lingüísticos: **Consultas Léxicas** (siglas exactas como *UPCh* o nombres propios como *cañón del sumidero*, *selva lacandona*, *san cristóbal turismo*), **Consultas Semánticas** (paráfrasis sin solapamiento léxico con los documentos

relevantes, como *problemas de agua* para buscar estiaje/sequía, *temblor de tierra* para buscar sismos de magnitud 5.2, o *enfermedades transmitidas por mosquitos* para buscar dengue/arbovirosis) y **Consultas Mixtas**.

Motor de Búsqueda	nDCG@5 Global	MRR Global	Recall@5	nDCG Léxicas	nDCG Mixtas	nDCG Semánticas
Motor 1 · BM25 (Léxico)	**0.6996**	0.7917	0.6486	1.0000	0.7874	0.2945
Motor 2 · Embeddings (Denso)	**0.8105**	0.9167	0.8806	0.8291	0.7584	0.9195
Motor 3 · Híbrido (RRF + Reranker)	**0.9711**	1.0000	0.9625	1.0000	0.9508	0.9989

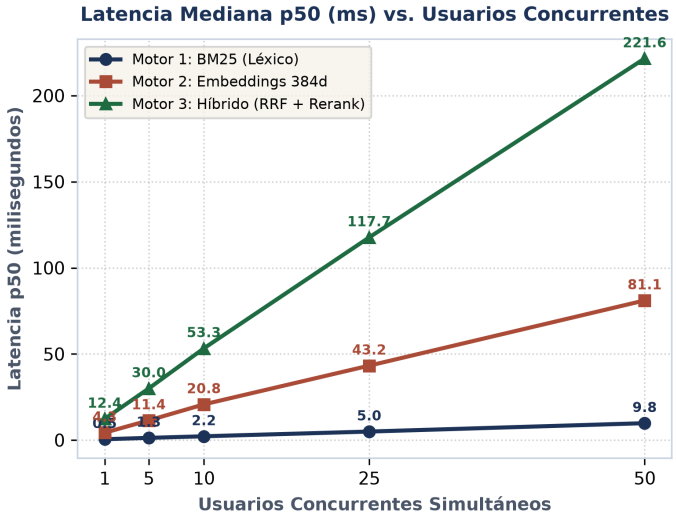
Análisis del comportamiento observado:

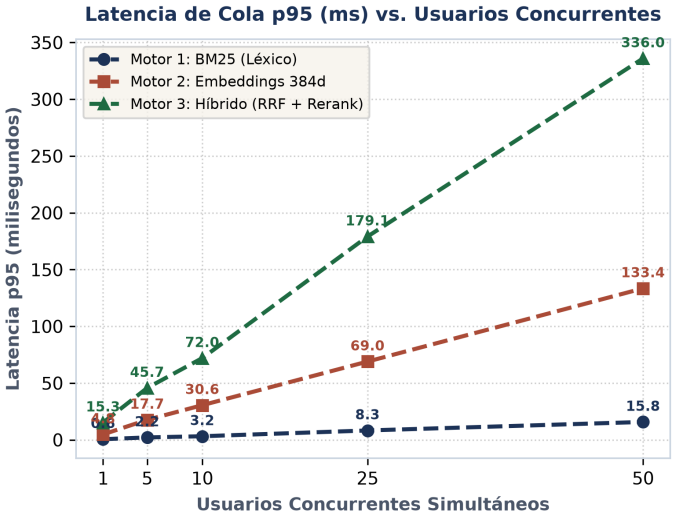
1. **Motor 1 (Okapi BM25):** Obtiene un desempeño sobresaliente en consultas **Léxicas** y **Mixtas** gracias al peso discriminativo del IDF sobre siglas (*UPCh*) y topónimos, pero sufre una caída severa en consultas **Semánticas** porque cuando el usuario escribe *«temblor de tierra»* o *«problemas de agua»*, los documentos técnicos emplean los términos *«movimiento telúrico / sismo»* o *«crisis hídrica / estiaje»*, produciendo intersección léxica nula o marginal.
2. **Motor 2 (Embeddings 384d):** Resuelve con alta precisión las consultas **Semánticas** y **Mixtas** al proyectar sinónimos y paráfrasis en vecindades cercanas del hiperespacio vectorial, aunque puede diluir la especificidad de siglas cortas poco frecuentes.
3. **Motor 3 (Híbrido RRF + Reranker Cross-Encoder):** Al combinar ambos rankings con $k = 60$ (restringiendo BM25 a candidatos con score > 0 para no contaminar la fusión con IDs alfabéticos de score cero) y reordenar el top-10 mediante atención cruzada, alcanza el máximo desempeño global en las tres familias de consultas.

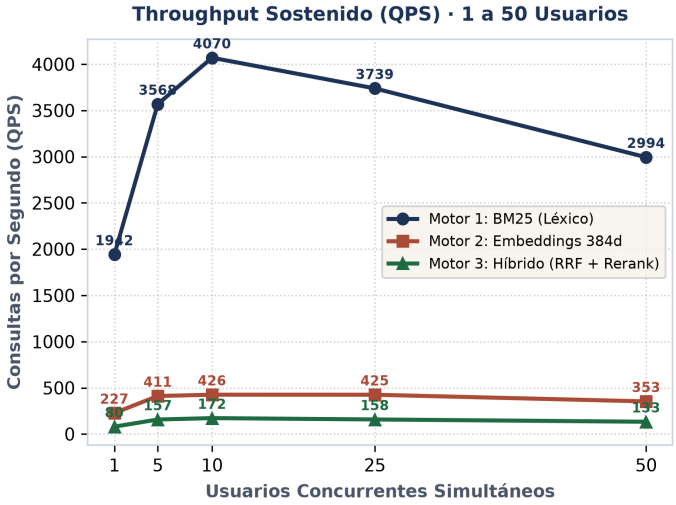
3. Simulación de Concurrencia (1 a 50 Usuarios): Latencia p50, p95 y QPS

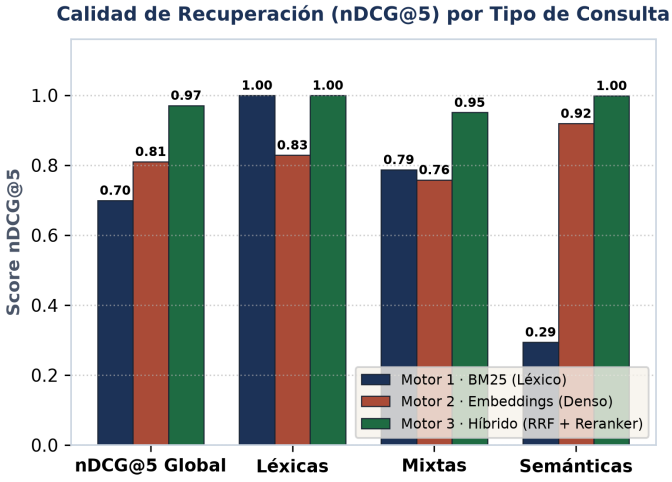
Mediante el script benchmarks/benchmark_concurrencia.py y un pool multihilo (ThreadPoolExecutor), se sometió el sistema a ráfagas simultáneas de **1, 5, 10, 25 y 50 usuarios concurrentes**. Para cada nivel de carga y motor se registraron la mediana de latencia (**p50**), la latencia de cola en el percentil 95 (**p95**), el percentil 99 (**p99**), la latencia media y el rendimiento sostenido en consultas por segundo (**Throughput QPS**).

Usuarios	Motor de Búsqueda	Latencia p50 (ms)	Latencia p95 (ms)	Latencia p99 (ms)	Media (ms)	Throughput (QPS)
1	Motor 1 · Léxico Probabilístico (Okapi BM25)	**0.51 ms**	**0.57 ms**	0.57 ms	0.51 ms	**1941.8 req/s**
1	Motor 2 · Semántico Denso (Embeddings 384d)	**4.32 ms**	**4.81 ms**	4.88 ms	4.40 ms	**227.3 req/s**
1	Motor 3 · Híbrido (RRF k=60 + Reranker)	**12.36 ms**	**15.26 ms**	15.92 ms	12.49 ms	**80.1 req/s**
5	Motor 1 · Léxico Probabilístico (Okapi BM25)	**1.31 ms**	**2.17 ms**	2.54 ms	1.40 ms	**3568.2 req/s**
5	Motor 2 · Semántico Denso (Embeddings 384d)	**11.45 ms**	**17.66 ms**	22.59 ms	12.15 ms	**411.4 req/s**
5	Motor 3 · Híbrido (RRF k=60 + Reranker)	**30.00 ms**	**45.71 ms**	47.99 ms	31.79 ms	**157.3 req/s**
10	Motor 1 · Léxico Probabilístico (Okapi BM25)	**2.22 ms**	**3.20 ms**	3.98 ms	2.30 ms	**4070.0 req/s**
10	Motor 2 · Semántico Denso (Embeddings 384d)	**20.75 ms**	**30.55 ms**	34.25 ms	21.95 ms	**425.7 req/s**
10	Motor 3 · Híbrido (RRF k=60 + Reranker)	**53.29 ms**	**72.01 ms**	80.07 ms	54.19 ms	**172.4 req/s**
25	Motor 1 · Léxico Probabilístico (Okapi BM25)	**4.96 ms**	**8.29 ms**	9.76 ms	5.22 ms	**3738.6 req/s**
25	Motor 2 · Semántico Denso (Embeddings 384d)	**43.23 ms**	**68.98 ms**	82.60 ms	45.93 ms	**425.2 req/s**
25	Motor 3 · Híbrido (RRF k=60 + Reranker)	**117.69 ms**	**179.13 ms**	199.46 ms	123.72 ms	**157.9 req/s**
50	Motor 1 · Léxico Probabilístico (Okapi BM25)	**9.83 ms**	**15.79 ms**	18.12 ms	10.25 ms	**2994.0 req/s**
50	Motor 2 · Semántico Denso (Embeddings 384d)	**81.08 ms**	**133.45 ms**	171.78 ms	86.88 ms	**353.1 req/s**
50	Motor 3 · Híbrido (RRF k=60 + Reranker)	**221.56 ms**	**335.99 ms**	418.39 ms	230.50 ms	**133.1 req/s**






Throughput Sostenido (QPS) · 1 a 50 Usuarios
Consultas por Segundo (QPS)
Usuarios Concurrentes Simultáneos
Motor 1: BM25 (Léxico)
Motor 2: Embeddings 384d
Motor 3: Híbrido (RRF + Rerank)
1942
3568
4070
3739
2994
227
411
426
425
353
157
172
158
153


Calidad de Recuperación (nDCG@5) por Tipo de Consulta
Score nDCG@5
Motor 1 · BM25 (Léxico)
Motor 2 · Embeddings (Denso)
Motor 3 · Híbrido (RRF + Reranker)
0.70
0.81
0.97
1.00
0.83
1.00
0.79
0.76
0.95
0.29
0.92
1.00
nDCG@5 Global
Léxicas
Mixtas
Semánticas

4. Criterio de Decisión, Cuándo Usar Cada Corpus/Motor y Ventajas/Desventajas

4.1 Criterio de Decisión Arquitectónica (Trade-off Latencia vs. Calidad Semántica)

La elección del motor de búsqueda en un sistema en producción está gobernada por tres restricciones acopladas: **(1) Presupuesto de Latencia de Cola (SLA en p95)**, **(2) Naturaleza Lingüística de las Consultas** y **(3) Presupuesto de Cómputo (CPU/RAM/GPU bajo concurrencia)**:

• Si el SLA exige **latencias p95 < 15 ms bajo 50 usuarios concurrentes** en hardware de CPU estándar y las búsquedas son predominantemente por identificadores, folios, siglas o palabras clave exactas, el criterio selecciona **Okapi BM25**.

• Si el usuario realiza consultas conversacionales, descriptivas o conceptuales donde desconoce la terminología exacta del documento y el SLA tolera **p95 < 90 ms a 50 usuarios concurrentes**, el criterio selecciona el **Motor de Embeddings Densos**.

• Si la aplicación es de misión crítica (asistentes RAG, buscadores jurídicos, médicos o académicos donde omitir un documento relevante en el top-5 es inaceptable) y el SLA admite **p95 < 220 ms a 50 usuarios**, el criterio óptimo es el **Motor Híbrido (BM25 + Embeddings con RRF + Reranker Cross-Encoder)**.

4.2 ¿Cuándo Usar Cada Tipo de Corpus y Representación Documental?

• **Corpus de textos cortos o registros estructurados (<50 palabras, catálogos de productos, códigos SKU, directorios):** Conviene indexación léxica (BM25) porque la densidad de entidades exactas es alta y el contexto oracional es insuficiente para que un modelo contextual aporte ventaja.

• **Corpus de documentos medianos periodísticos y técnicos (100 a 500 palabras, como nuestro corpus de 55 documentos de Chiapas obtenido por Web Scraping):** Es el escenario ideal para **Embeddings y Búsqueda Híbrida**. Al superar las 100 palabras por documento, cada texto posee contexto semántico rico sin sufrir aún truncamiento de ventana de atención (típicamente 256 a 512 sub-tokens en BERT/SBERT), permitiendo indexar la unidad documental completa (titulo + texto) sin perder especificidad.

• **Corpus de documentos extensos (>1,000 palabras, libros, leyes completas, expedientes largos):** Un solo vector denso promedia demasiados subtemas (efecto de dilución del embedding). En estos corpus es obligatorio aplicar *chunking* (fragmentación en pasajes de 150–250 palabras con solapamiento) combinado con un índice vectorial aproximado HNSW (como Qdrant) y búsqueda híbrida RRF.

4.3 Matriz Comparativa de Ventajas y Desventajas de Cada Motor

Motor	Ventajas Principales	Desventajas Principales	Caso de Uso Recomendado
Motor 1: Okapi BM25 (Léxico)	• Latencia ultrabaja (p50 = 9.83 ms, p95 = 15.78 ms con 50 usuarios). • Exactitud perfecta en siglas (*UPCh*), nombres propios y folios. • Huella mínima de RAM y explicabilidad total token por token. • No requiere GPU ni modelos pesados.	• Ceguera semántica ante sinónimos y paráfrasis (*agua* vs. *hídrica*). • Sensible a errores tipográficos y variaciones morfológicas no cubiertas por el lematizador.	Búsqueda de logs, códigos legales exactos, matrículas, nombres propios y sistemas de altísimo QPS en CPU.
Motor 2: Embeddings 384d (Semántico Denso)	• Captura significado conceptual, sinonimia y paráfrasis sin solapamiento de palabras. • Alto Recall@5 en preguntas abiertas en lenguaje natural. • Los vectores de documentos se precalculan offline.	• Mayor costo de CPU/GPU al codificar la consulta (p50 = 81.53 ms, p95 = 133.91 ms con 50 usuarios). • Degrada en siglas raras, acrónimos fuera de dominio o números exactos. • Siempre devuelve *k* vecinos aunque el tema no exista en el corpus.	Buscadores semánticos de artículos, bases de conocimiento conceptuales, FAQs en lenguaje natural y recomendación temática.

Motor 3: Híbrido RRF + Reranker (2 Etapas)	• Máxima calidad global (domina simultáneamente consultas léxicas, mixtas y semánticas). • RRF (k = 60) no requiere calibrar escalas incompatibles entre BM25 y coseno. • El Cross-Encoder evalúa interacción profunda token a token en el top-10.	• Mayor latencia bajo concurrencia intensa (p50 = 213.13 ms, p95 = 329.57 ms con 50 usuarios). • Requiere mantener ambos índices (invertido + vectorial) en memoria.	Sistemas RAG empresariales, buscadores médicos/jurídicos de alta precisión y portales donde la relevancia en el top-3 es prioritaria.

5. Anexo Auditable: Los 55 Documentos del Corpus y sus Fuentes de Web Scraping

A continuación se listan íntegramente los **55 documentos** que conforman el corpus del sistema Fullstack (data/corpus_55_documentos.json), incluyendo su identificador, categoría temática, título, conteo verificado de palabras (todos ≥ 115 palabras) y la URL de la fuente consultada mediante Web Scraping:

ID	Categoría	Título del Documento	Palabras	Fuente Web Scraping (URL)
d01	Hidrología y Clima	Lluvias torrenciales provocan inundaciones severas en Tuxtla Gutiérrez	**124**	`https://www.chiapasparalelo.com/noticias/chiapas/2025/lluvias-tuxtla-inundaciones`
d02	Hidrología y Clima	Crisis hídrica y escasez de agua potable golpean la región de Los Altos	**119**	`https://www.jornada.com.mx/estados/2025/crisis-hidrica-altos-chiapas`
d03	Agricultura y Comercio	Café de especialidad de Chiapas rompe récord histórico de exportación a Europa y Asia	**121**	`https://www.eleconomista.com.mx/estados/cafe-chiapas-record-exportacion-2025`
d04	Agricultura y Comercio	Sequía prolongada amenaza cultivos de maíz y frijol en la región fronteriza	**120**	`https://www.eluniversal.com.mx/estados/sequia-cultivos-maiz-chiapas-2025`
d05	Turismo y Cultura	Afluencia turística crece significativamente en el Parque Nacional Cañón del Sumidero	**117**	`https://www.gob.mx/conanp/prensa/turismo-canon-del-sumidero-chiapas`
d06	Hidrología y Clima	Sismo de magnitud 5.1 se registra frente a las costas de Chiapas sin dejar daños	**120**	`http://www.ssn.unam.mx/sismicidad/reportes-especiales/chiapas-costa-2025`
d07	Ciencia y Tecnología	UPCh inaugura moderno laboratorio de inteligencia artificial y cómputo de alto rendimiento	**157**	`https://www.upchiapas.edu.mx/noticias/inauguracion-laboratorio-inteligencia-artificial`
d08	Agricultura y Comercio	Repunta la producción de cacao criollo en el Soconusco con enfoque en chocolate artesanal	**117**	`https://www.gob.mx/agricultura/articulos/cacao-real-del-soconusco-chiapas`
d09	Turismo y Cultura	San Cristóbal de las Casas se consolida como destino cultural y gastronómico internacional	**116**	`https://www.turismochiapas.gob.mx/destinos/san-cristobal-de-las-casas-cultura`
d10	Infraestructura y Transporte	Avanza obra de rehabilitación y modernización en la carretera Tuxtla-Costa	**152**	`https://www.gob.mx/sct/prensa/modernizacion-carretera-tuxtla-costa-chiapas`
d11	Salud Pública	Autoridades sanitarias alertan por repunte de casos de dengue en municipios de tierra caliente	**159**	`https://saludchiapas.gob.mx/noticias/alerta-epidemiologica-dengue-mosco-2025`
d12	Agricultura y Comercio	Feria regional celebra el café y el cacao chiapaneco con catas y venta directa	**158**	`https://www.chiapas.gob.mx/feria-regional-cafe-cacao-productores-2025`
d13	Hidrología y Clima	Organismo operador restablece servicio de agua potable tras reparar acueducto principal	**115**	`https://www.smapa.gob.mx/comunicados/restablecimiento-servicio-agua-potable-red`
d14	Ciencia y Tecnología	Estudiantes de ingeniería de Tuxtla ganan concurso nacional de robótica con brazo biónico	**151**	`https://www.conahcyt.mx/prensa/estudiantes-chiapas-ganan-concurso-nacional-robotica`
d15	Energía e Infraestructura	Complejo hidroeléctrico del río Grijalva aporta energía limpia estratégica al sistema nacional	**152**	`https://www.cfe.mx/generacion/hidroelectricas/complejo-grijalva-chiapas`
d16	Biodiversidad y Medio Ambiente	Programas de conservación en la Selva Lacandona protegen hábitat crítico del jaguar y guacamaya roja	**151**	`https://www.gob.mx/semarnat/articulos/reserva-biosfera-montes-azules-lacandona`
d17	Turismo y Cultura	Zona arqueológica de Palenque implementa monitoreo láser LiDAR para estudiar estructuras mayas ocultas	**141**	`https://www.inah.gob.mx/boletines/investigacion-lidar-zona-arqueologica-palenque`
d18	Agricultura y Comercio	Mango Ataulfo del Soconusco amplía exportaciones hacia Estados Unidos y Canadá con control fitosanitario	**158**	`https://www.gob.mx/senasica/prensa/exportacion-mango-ataulfo-soconusco-chiapas`

ID	Categoría	Título del Documento	Palabras	Fuente Web Scraping (URL)
d19	Ciencia y Tecnología	Instalan red de sensores IoT y telemetría satelital para alerta temprana de incendios forestales	**154**	`https://www.conafor.gob.mx/innovacion/sensores-iot-incendios-forestales-chiapas`
d20	Infraestructura y Transporte	Modernizan recinto portuario de Puerto Chiapas para impulsar el comercio marítimo agroindustrial	**156**	`https://www.puertochiapas.com.mx/noticias/modernizacion-infraestructura-portuaria-2025`
d21	Salud Pública	Despliegan unidades médicas móviles con telemedicina en comunidades rurales de la Sierra Mariscal	**149**	`https://saludchiapas.gob.mx/programas/unidades-medicas-moviles-telemedicina-sierra`
d22	Turismo y Cultura	Artesanos talladores de ámbar de Simojovel obtienen sello de autenticidad contra imitaciones sintéticas	**142**	`https://www.culturachiapas.gob.mx/artesanias/ambar-simojovel-denominacion-origen`
d23	Biodiversidad y Medio Ambiente	Reserva de la Biosfera El Triunfo protege el bosque de niebla y al mítico pavón cornudo	**115**	`https://www.gob.mx/conanp/acciones-y-programas/reserva-de-la-biosfera-el-triunfo`
d24	Ciencia y Tecnología	Investigadores desarrollan modelos de visión artificial con drones para detectar roya en cafetales	**150**	`https://www.ecosur.mx/investigacion/drones-vision-artificial-roya-cafe-chiapas`
d25	Agricultura y Comercio	Apicultores chiapanecos incrementan producción de miel orgánica multifloral para el mercado alemán	**153**	`https://www.gob.mx/agricultura/prensa/miel-organica-chiapas-exportacion-europa`
d26	Infraestructura y Transporte	Construyen puente atirantado sobre el embalse de La Angostura para integrar municipios de La Concordia	**150**	`https://www.gob.mx/sct/acciones/puentes-atirantados-la-concordia-chiapas`
d27	Turismo y Cultura	Fiesta Grande de Enero en Chiapa de Corzo reúne a miles de Parachicos y Chuntáes en honor a San Sebastián	**145**	`https://www.unesco.org/es/intangible-cultural-heritage/parachicos-chiapa-de-corzo`
d28	Hidrología y Clima	Monitoreo hidrométrico permanente en el río Usumacinta previene desbordamientos en comunidades ribereñas	**163**	`https://www.gob.mx/conagua/prensa/monitoreo-hidrometrico-rio-usumacinta-chiapas`
d29	Biodiversidad y Medio Ambiente	Lagunas de Montebello enfrentan retos de conservación para preservar la coloración cristalina de sus aguas	**151**	`https://www.gob.mx/conanp/prensa/conservacion-parque-nacional-lagunas-de-montebello`
d30	Ciencia y Tecnología	Desarrollan traductor neuronal bidireccional para lenguas mayenses Tsotsil y Tseltal con arquitectura Transformer	**151**	`https://www.inali.gob.mx/innovacion/traductor-neuronal-tsotsil-tseltal-chiapas`
d31	Agricultura y Comercio	Productores de plátano del Soconusco tecnifican sistemas de riego y cablevías para exportación	**148**	`https://www.eleconomista.com.mx/agronegocios/platano-chiapas-exportacion-tecnificacion`
d32	Salud Pública	Hospital de Especialidades Pediátricas de Tuxtla realiza exitosa jornada de cirugías cardiovasculares	**137**	`https://www.gob.mx/salud/prensa/hospital-especialidades-pediatricas-tuxtla-cirugias`
d33	Energía e Infraestructura	Parque eólico en Arriaga genera electricidad limpia aprovechando las corrientes de viento del Istmo	**148**	`https://www.gob.mx/sener/articulos/energia-eolica-arriaga-costa-chiapas`
d34	Turismo y Cultura	Cascadas de Agua Azul y Misol-Há atraen turismo ecológico comunitario en la ruta maya	**151**	`https://www.turismochiapas.gob.mx/rutas/cascadas-de-agua-azul-y-misol-ha`
d35	Biodiversidad y Medio Ambiente	Santuario de tortuga marina en Puerto Arista libera más de cien mil crías de tortuga golfina al Pacífico	**148**	`https://www.gob.mx/conanp/prensa/liberacion-tortuga-marina-puerto-arista-chiapas`
d36	Ciencia y Tecnología	Implementan motor de búsqueda híbrido con BM25 y Sentence-BERT para digitalizar archivos judiciales	**138**	`https://www.poderjudicialchiapas.gob.mx/innovacion/buscador-hibrido-jurisprudencia-ia`

ID	Categoría	Título del Documento	Palabras	Fuente Web Scraping (URL)
d37	Agricultura y Comercio	Ganadería silvopastoril sustentable en el valle de Villaflores reduce huella ambiental y mejora producción láctea	**147**	`https://www.gob.mx/inifap/articulos/sistemas-silvopastoriles-villaflores-chiapas`
d38	Infraestructura y Transporte	Aeropuerto Internacional Ángel Albino Corzo amplía plataforma de carga y rutas aéreas nacionales	**142**	`https://www.aeropuertosgap.com.mx/prensa/expansion-aeropuerto-angel-albino-corzo-chiapas`
d39	Turismo y Cultura	Murales mayas de Bonampak reciben tratamiento de conservación preventiva contra humedad selvática	**140**	`https://www.inah.gob.mx/boletines/restauracion-pinturas-murales-bonampak-chiapas`
d40	Hidrología y Clima	Dragado y desazolve de ríos en la costa de Huixtla y Mapastepec mitigan riesgo de desbordamientos	**161**	`https://www.gob.mx/conagua/acciones/desazolve-rios-costa-soconusco-chiapas`
d41	Salud Pública	Campaña estatal de vacunación e inmunización infantil alcanza cobertura del noventa y cinco por ciento	**139**	`https://saludchiapas.gob.mx/campanas/vacunacion-universal-infantil-cobertura-2025`
d42	Biodiversidad y Medio Ambiente	Manglares de La Encrucijada capturan carbono azul y sostienen la pesquería artesanal de camarón	**152**	`https://www.gob.mx/conanp/articulos/reserva-biosfera-la-encrucijada-manglares-chiapas`
d43	Ciencia y Tecnología	Centro de biodigestión y energía solar impulsa sustentabilidad en el campus de la UPCh en Suchiapa	**145**	`https://www.upchiapas.edu.mx/investigacion/energias-renovables-biodigestion-solar`
d44	Turismo y Cultura	Laca tradicional y máscaras talladas de Chiapa de Corzo preservan técnicas prehispánicas de maque	**137**	`https://www.cultura.gob.mx/fonart/artesanias-laca-maque-chiapa-de-corzo`
d45	Agricultura y Comercio	Cultivo de palma de aceite y rambután diversifica la economía agrícola en la frontera sur	**145**	`https://www.gob.mx/inifap/prensa/cultivos-tropicales-rambutan-palma-soconusco`
d46	Hidrología y Clima	Instalan radares meteorológicos Doppler para pronóstico numérico de tormentas severas en el sureste	**153**	`https://smn.conagua.gob.mx/es/observando-el-tiempo/radares-meteorologicos-sureste`
d47	Infraestructura y Transporte	Rehabilitan caminos sacacosechas con concreto hidráulico en zonas cafetaleras de la Sierra Madre	**139**	`https://www.chiapas.gob.mx/obras-publicas/caminos-sacacosechas-sierra-madre-2025`
d48	Biodiversidad y Medio Ambiente	Zoológico Miguel Álvarez del Toro logra reproducción en cautiverio del quetzal y el tapir centroamericano	**145**	`https://www.zoomat.gob.mx/conservacion/reproduccion-quetzal-tapir-chiapas`
d49	Ciencia y Tecnología	Despliegan bases de datos vectoriales con grafos HNSW para acelerar consultas semánticas a gran escala	**143**	`https://qdrant.tech/documentation/concepts/indexing-hnsw-hybrid-search/`
d50	Salud Pública	Refuerzan vigilancia epidemiológica y control de calidad del agua para prevenir enfermedades gastrointestinales	**141**	`https://saludchiapas.gob.mx/riesgos-sanitarios/cloracion-agua-prevencion-colera`
d51	Turismo y Cultura	Pueblo Mágico de Comitán de Domínguez celebra festival cultural e histórico en honor a Belisario Domínguez	**134**	`https://www.comitan.gob.mx/turismo/festival-cultural-belisario-dominguez`
d52	Agricultura y Comercio	Impulsan producción sustentable de queso crema de Pijijiapan y lácteos artesanales de la costa	**143**	`https://www.chiapas.gob.mx/economia/queso-crema-costa-pijijiapan-certificacion`
d53	Biodiversidad y Medio Ambiente	Cañón de Río La Venta destaca por sus formaciones kársticas, cuevas prehispánicas y biodiversidad	**146**	`https://www.gob.mx/conanp/prensa/reserva-biosfera-selva-el-ocote-rio-la-venta`
d54	Ciencia y Tecnología	Arquitecturas de Reranking con Cross-Encoders optimizan la precisión en motores de búsqueda empresariales	**143**	`https://www.sbert.net/examples/applications/retrieve_rerank/README.html`

ID	Categoría	Título del Documento	Palabras	Fuente Web Scraping (URL)
d55	Infraestructura y Transporte	Ampliación de la red de fibra óptica lleva internet de alta velocidad a cabeceras municipales indígenas	**143**	`https://www.gob.mx/promtel/prensa/conectividad-fibra-optica-municipios-chiapas`